

第二章 统计分析

1. 一维数据的统计分析

2. 多维数据的统计分析

统计学基础

统计数据类型

按计量尺度

- 分类数据
- 顺序数据
- 数值型数据

几个基本概念

- 变量
 - 分类变量
 - 顺序变量
 - 数值型变量
- 总体和样本
- 参数和统计量

描述性统计分析

- 集中趋势的度量
 - 众数
 - 平均数
 - 中位数
 - 四分位数
- 离散趋势的度量
 - 极差
 - 方差
 - 标准差
 - 标准分数
- 偏态与峰态的度量
 - 偏态
 - 峰态

自由度

常用统计量及其抽样分布

- 样本均值的分布
- 样本比例的分布
- 两个样本均值之差的分布
- 关于样本方差的分布

- **数据的统计分析又称为描述性分析，顾名思义，就是从统计的角度进行数据分析，也就是分析统计中常用的统计量（值），即样本均值、样本方差、分位数、中位数、极差、样本偏度、样本峰度等。**
- **从数据的维数分为一维数据的统计特征和 multidimensional 数据的统计特征。**

1. 一维数据的统计分析

- **(1) 表示位置水平的数字特征**
- **(2) 表示分散趋势的数字特征**
- **(3) 表示分布形状的数字特征**

1. 一维数据的统计分析

- (1) 表示位置水平的数字特征——**样本均值**:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

缺点：不具备稳健性。

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**中位数**:

将 x_1, x_2, \dots, x_n 从小到大排序为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$

样本中位数的位置: $\frac{n+1}{2}$

样本中位数:

$$M = \begin{cases} x_{(\frac{n+1}{2})}, & n \text{ 为奇数} \\ \frac{1}{2} (x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}), & n \text{ 为偶数.} \end{cases}$$

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**例题**:

例2-1.随机抽取30名大学生，得到某课程的考试分数数据如下：

**59,77,97,60,88,63,64,65,75,67,67,69,73,70,66,76,76,54,77,85,78,
78,79,61,83,93,86,91,71,80.**

计算30名学生考试分数的中位数。

解：首先将30个分数排序，结果如下：

**54,59,60,61,63,64,65,66,67,67,69,70,71,73,75,76,7
6,77,77,78,78,79,80,83,85,86,88,91,93,97.**

然后确定中位数的位置和数值：

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**例题**:

$$\text{中位数位置} = (n+1) / 2 = 15.5$$

中位数是第15个数值 (75) 和第16个数值 (76) 的平均数,
即

$$\text{中位数} = (75+76)/2 = 75.5$$

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**样本百分位数**:

将 x_1, x_2, \dots, x_n 从小到大排序为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$

样本百分位数的位置: $q = \frac{p}{100}(n+1)$ $p = 1, 2, \dots, 99$

其中: p 为分位

样本百分位数:

- 若位置 q 为整数, 则 p 百分位数为 $M_p = x_{(q)}$
- 若位置 q 为小数, 则 p 百分位数为 $M_p = x_{([q])} + d(x_{([q]+1)} - x_{([q])})$

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**样本百分位数**:

将 x_1, x_2, \dots, x_n 从小到大排序为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$

$$M_p = \begin{cases} x_{(\lfloor \frac{np}{100} \rfloor + 1)}, & \frac{np}{100} \text{ 不是整数} \\ \frac{1}{2} (x_{(\frac{np}{100})} + x_{(\frac{np}{100} + 1)}), & \frac{np}{100} \text{ 是整数.} \end{cases}$$

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**例题**:

例2-2.沿用例2-1.计算30名学生考试分数的第5个百分位数和第90个百分位数。

解：首先将30个分数排序，结果如下：

**54,59,60,61,63,64,65,66,67,67,69,70,71,73,75,76,76,77,77,78,78,
79,80,83,85,86,88,91,93,97.**

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**例题**:

确定第5个分位数的位置

$$P5\% \text{位置} = 5/100 * (30+1) = 1.55$$

**故第5个分位数在第1个值（54）和第2个值（59）之间
0.55的位置上，因此**

$$\text{所求第5个百分位数} = 54 + 0.55(59-54) = 56.75.$$

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**例题**:

第90个百分位数的位置为

$$P90\% \text{位置} = 90/100 * (30+1) = 27.9$$

因此第90个分位数在第27个值 (88) 和第28个值 (91) 之间0.9的位置上, 故

$$\text{第90个百分位数} = 88 + 0.9(91-88) = 90.7$$

1. 一维数据的统计分析

➤ (1) 表示位置水平的数字特征——**上、下四分位数**:

75分位数与25分位数分别称为上、下四分位数，并记为

$$Q_3 = M_{75} \qquad Q_1 = M_{25}$$

最小值, Q1, 中位数, Q3, 最大值

1. 一维数据的统计分析

➤ (2) 表示波动（分散）的统计特征——**样本方差**：

样本方差：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

根方差：样本方差开根号。

1. 一维数据的统计分析

➤ (2) 表示波动（分散）的统计特征——**样本极差**：

将 x_1, x_2, \dots, x_n 从小到大排序为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$

样本极差：

$$R = x_{(n)} - x_{(1)}$$

1. 一维数据的统计分析

➤ (2) 表示波动（分散）的统计特征——**样本四分位极差**：

将 x_1, x_2, \dots, x_n 从小到大排序为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$

样本四分位极差：

$$R_1 = Q_3 - Q_1$$

1. 一维数据的统计分析

- (2) 表示波动（分散）的统计特征——**下、上截断点**:

下、上截断点:

$$Q_1 - 1.5R_1$$

$$Q_3 + 1.5R_1$$

异常值： 小于下截断点以及大于上截断点的值统称为异常值

1. 一维数据的统计分析

- (2) 表示波动（分散）的统计特征——**变异系数**:

变异系数:

$$CV = 100 * \text{标准差} / \text{样本均值}(\%)$$

1. 一维数据的统计分析

➤ (3)表示形状的统计特征——**样本偏度**:

样本偏度:

$$g_1 = \frac{n}{(n-1)(n-2)} \frac{1}{s^3} \sum_{i=1}^n (x_i - \bar{x})^3$$

偏度大于0, 右偏 (正偏) ;

偏度小于0, 左偏 (负偏) ;

偏度等于0, 数据分布左右对称。

1. 一维数据的统计分析

➤ (3)表示形状的统计特征——**样本峰度**:

样本峰度:

$$g_2 = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \frac{1}{s^4} \sum_{i=1}^n (x_i - \bar{x})^4 - \frac{3(n-1)^2}{(n-2)(n-3)}$$

峰度大于0，有较多远离均值的极端数值；

峰度小于0，均值两侧的极端数值较少；

峰度等于0，数据分布为正态分布。

2. 多维数据的统计分析

- **(1) 多维数据的均值向量**
- **(2) 多维数据的协方差阵**
- **(3) 多维数据的相关阵**

2. 多维数据的统计分析

➤ (1) 多维数据的均值向量:

总体X的观测值为 $X_i = (x_{i1}, x_{i2}, \dots, x_{im})^T, i = 1, 2, \dots, n$

样本观测矩阵

$$\begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{pmatrix} = \begin{pmatrix} X_1^T \\ X_2^T \\ \vdots \\ X_n^T \end{pmatrix}$$

2. 多维数据的统计分析

➤ (1) 多维数据的均值向量:

总体X的观测值为 $X_i = (x_{i1}, x_{i2}, \dots, x_{im})^T, i = 1, 2, \dots, n$

样本均值向量

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \left(\frac{1}{n} \sum_{i=1}^n x_{i1}, \frac{1}{n} \sum_{i=1}^n x_{i2}, \dots, \frac{1}{n} \sum_{i=1}^n x_{im} \right)^T \hat{=} (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_m)^T$$

2. 多维数据的统计分析

➤ (2) 多维数据的协方差阵:

总体X的观测值为 $X_i = (x_{i1}, x_{i2}, \dots, x_{im})^T, i = 1, 2, \dots, n$

样本协方差阵

$$\hat{\Sigma} = \begin{pmatrix} \hat{\sigma}_{11} & \hat{\sigma}_{12} & \cdots & \hat{\sigma}_{1m} \\ \hat{\sigma}_{21} & \hat{\sigma}_{22} & \cdots & \hat{\sigma}_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ \hat{\sigma}_{m1} & \hat{\sigma}_{m1} & \cdots & \hat{\sigma}_{mm} \end{pmatrix} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^T$$

2. 多维数据的统计分析

➤ (2) 多维数据的协方差阵:

其中

$$\hat{\sigma}_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j), i, j = 1, 2, \dots, m$$

2. 多维数据的统计分析

➤ (3) 多维数据的相关阵:

总体X的观测值为 $X_i = (x_{i1}, x_{i2}, \dots, x_{im})^T, i = 1, 2, \dots, n$

样本相关阵

$$\hat{R} = \begin{pmatrix} 1 & \hat{\rho}_{12} & \cdots & \hat{\rho}_{1m} \\ \hat{\rho}_{21} & 1 & \cdots & \hat{\rho}_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ \hat{\rho}_{m1} & \hat{\rho}_{m1} & \cdots & 1 \end{pmatrix}$$

2. 多维数据的统计分析

➤ (3) 多维数据的相关阵:

其中

$$\hat{\rho}_{ij} = \frac{\hat{\sigma}_{ij}}{\sqrt{\hat{\sigma}_{ii} \times \hat{\sigma}_{jj}}}, i, j = 1, 2, \dots, m$$

2. 多维数据的统计分析

例2-6 设 $(0, 1)'$, $(1, 2)'$, $(2, 6)'$, 为来自总体 $X = (X_1, X_2)'$ 的一个样本长度为3的样本值, 求 X 的协方差矩阵 Σ 、相关矩阵 R 。

解: $\bar{X} = \left(\frac{1}{3} \sum_{i=1}^3 x_{i1}, \frac{1}{3} \sum_{i=1}^3 x_{i2} \right)' = (\bar{X}_1, \bar{X}_2)' = (1, 3)'$

$$\begin{aligned}\hat{\Sigma} &= \frac{1}{3-1} \sum_{i=1}^3 (X_i - \bar{X})(X_i - \bar{X})' \\ &= \frac{1}{2} \left(\begin{pmatrix} -1 \\ -2 \end{pmatrix} (-1, -2) + \begin{pmatrix} 0 \\ -1 \end{pmatrix} (0, -1) + \begin{pmatrix} 1 \\ 3 \end{pmatrix} (1, 3) \right) \\ &= \frac{1}{2} \left(\begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 3 \\ 3 & 9 \end{pmatrix} \right) = \begin{pmatrix} 1 & 5/2 \\ 5/2 & 7 \end{pmatrix}\end{aligned}$$

2. 多维数据的统计分析

例2-6 设 $(0, 1)'$, $(1, 2)'$, $(2, 6)'$, 为来自总体 $X = (X_1, X_2)'$ 的一个样本长度为3的样本值, 求 X 的协方差矩阵 Σ 、相关矩阵 R 。

解: $\bar{X} = (\frac{1}{3} \sum_{i=1}^3 x_{i1}, \frac{1}{3} \sum_{i=1}^3 x_{i2})' = (\bar{X}_1, \bar{X}_2)' = (1, 3)'$

或 $\hat{\sigma}_{11} = \frac{1}{n-1} \sum_{l=1}^n (x_{l1} - \bar{x}_1)(x_{l1} - \bar{x}_1) = \frac{1}{2} ((-1)^2 + 0^2 + 1^2) = 1$

$$\hat{\sigma}_{12} = \frac{1}{n-1} \sum_{l=1}^n (x_{l1} - \bar{x}_1)(x_{l2} - \bar{x}_2) = \frac{1}{2} ((-1) \times (-2) + 0 + 1 \times 3) = \frac{5}{2}$$

$$\hat{\sigma}_{22} = \frac{1}{n-1} \sum_{l=1}^n (x_{l2} - \bar{x}_2)(x_{l2} - \bar{x}_2) = \frac{1}{2} ((-2)^2 + (-1)^2 + 3^2) = 7$$

2. 多维数据的统计分析

$$\hat{\rho}_{12} = \frac{\hat{\sigma}_{12}}{\sqrt{\hat{\sigma}_{11}} \sqrt{\hat{\sigma}_{22}}} = \frac{5/2}{1 \times \sqrt{7}} = \frac{5\sqrt{7}}{14}$$

$$\hat{\mathbf{R}} = \begin{pmatrix} 1 & \frac{5}{14}\sqrt{7} \\ \frac{5}{14}\sqrt{7} & 1 \end{pmatrix}$$