

# 第七章 线性与非线性方程组的迭代解法

数值计算方法课程组

中国石油大学-华东

(课堂专属 切勿网传)



中国石油大学(华东)  
CHINA UNIVERSITY OF PETROLEUM

理论上, **直接法**得到的解是准确的, 但是我们可以看得出, 它们的计算量都是  $n^3$  数量级, 存储量为  $n^2$  量级, 这在  $n$  比较小的时候还比较合适, 但是对于现在的很多实际问题, 往往要我们求解很大的  $n$  的矩阵, 而且这些矩阵往往是系数矩阵就是这些矩阵含有大量的 0 元素。对于这类的矩阵, 在用直接法时就会耗费大量的时间和存储单元. 因此我们有必要引入一类新的方法: 迭代法.

**迭代法**具有的特点是**速度快**。与非线性方程的迭代方法一样, 需要我们构造一个等价的方程, 从而建立一个收敛序列, 序列的极限值就是方程组的根. 例如, 解方程

$$Ax = b$$

做等价变换

$$x = Mx + g$$

从而建立迭代格式

$$x^{(k+1)} = Mx^{(k)} + g, \quad k = 0, 1, \dots$$

从初值  $x^{(0)}$  出发, 产生迭代序列  $x^{(k)}$ , 若其收敛得到原问题的解。

### 迭代法的优点

- 程序简单, 存储量小;
- 适用于求解系数矩阵为大型稀疏矩阵问题.

# 目 录

- ① Jacobi 迭代法与 Gauss-Seidel 迭代法
- ② Jacobi 迭代与 Gauss-Seidel 迭代的收敛性分析
- ③ 超松弛迭代法
- ④ 共轭梯度法
- ⑤ 非线性方程组的迭代解法

# 目录

- 1 Jacobi 迭代法与 Gauss-Seidel 迭代法
- 2 Jacobi 迭代与 Gauss-Seidel 迭代的收敛性分析
- 3 超松弛迭代法
- 4 共轭梯度法
- 5 非线性方程组的迭代解法

## §7.1.1 Jacobi 迭代法

考虑非奇异线性代数方程组

$$Ax = b, \quad A = (a_{ij})_{n \times n}, \quad \det(A) \neq 0 \quad (1.1)$$

令

$$A = D - L - U$$

其中

$$D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn}),$$

$$L = \begin{bmatrix} 0 & & & & \\ -a_{21} & 0 & & & \\ -a_{31} & -a_{32} & 0 & & \\ \vdots & \dots & \ddots & \ddots & \\ -a_{11} & -a_{n2} & \dots & -a_{n,n-1} & 0 \end{bmatrix}, \quad U = \begin{bmatrix} 0 & -a_{12} & -a_{13} & \dots & -a_{1n} \\ & 0 & -a_{23} & \dots & -a_{2n} \\ & & 0 & \ddots & \vdots \\ & & & \ddots & -a_{n-1,n} \\ & & & & 0 \end{bmatrix}$$

可将 (1.1) 可写为如下等价形式

$$x = Bx + g, \quad B = D^{-1}(L + U), \quad g = D^{-1}b. \quad (1.2)$$

若给定初始向量  $x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T$  从而可以建立如下迭代格式

$$x^{(k+1)} = Bx^{(k)} + g, \quad k = 0, 1, 2, 3, \dots \quad (1.3)$$

此方法称为 Jacobi 迭代法， $B$  称为 Jacobi 迭代矩阵， $g$  称为常数项。其分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right), \quad i = 1, 2, \dots, n \quad (1.4)$$

例：写出 Jacobi 迭代法求解下列方程组的迭代格式

$$\begin{bmatrix} 10 & 3 & 1 \\ 2 & -10 & 3 \\ 1 & 3 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 14 \\ -5 \\ 14 \end{bmatrix}$$

解：Jacobi 迭代公式为

$$\begin{aligned} x_1^{(k+1)} &= (14 - 3x_2^{(k)} - x_3^{(k)})/10 \\ x_2^{(k+1)} &= (-5 - 2x_1^{(k)} - 3x_3^{(k)})/(-10) \\ x_3^{(k+1)} &= (14 - x_1^{(k)} - 3x_2^{(k)})/10 \end{aligned}$$



# Jacobi 迭代法算例

若取初值  $x^{(0)} = (0, 0, 0)^T$ , 选取不同的精度要求计算, 结果如下表

精度要求	迭代次数	近似解
0.001	9	(1.0002507 1.0000694 1.0002507)
0.0001	12	(1.0000102 0.9999835 1.0000102)
0.00001	14	(0.9999981 1.0000020 0.9999981)

## §7.1.2 Gauss-Seidel 迭代法

在 Jacobi 迭代法 (1.4) 中, 计算  $x_i^{(k+1)}$  时, 利用已经计算出来的  $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ , 可以得到 Gauss-Seidel 迭代法, 即

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 1, 2, \dots, n \quad (1.5)$$

显然, Gauss-Seidel 迭代法是 Jacobi 迭代法的一种改进. 其向量形式表示为

$$x^{(k+1)} = D^{-1} L x^{(k+1)} + D^{-1} U x^{(k)} + D^{-1} b, \quad k = 0, 1, 2, 3, \dots \quad (1.6)$$

特别, 矩阵  $D - L$  可逆时, Gauss-Seidel 迭代法可表示为

$$x^{(k+1)} = (D - L)^{-1} U x^{(k)} + (D - L)^{-1} b, \quad k = 0, 1, 2, 3, \dots \quad (1.7)$$

例：写出 Gauss-Seidel 迭代法求解下列方程组的迭代格式

$$\begin{bmatrix} 10 & 3 & 1 \\ 2 & -10 & 3 \\ 1 & 3 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 14 \\ -5 \\ 14 \end{bmatrix}$$

解：Gauss-Seidel 迭代公式为

$$\begin{aligned} x_1^{(k+1)} &= (14 - 3x_2^{(k)} - x_3^{(k)})/10 \\ x_2^{(k+1)} &= (-5 - 2x_1^{(k+1)} - 3x_3^{(k)})/(-10) \\ x_3^{(k+1)} &= (14 - x_1^{(k+1)} - 3x_2^{(k+1)})/10 \end{aligned}$$

# Gauss-Seidel 迭代法算例

若取初值  $x^{(0)} = (0, 0, 0)^T$ , 选取不同的精度要求计算, 结果如下表

方法	精度要求	迭代次数	近似解
G-S	0.001	6	(1.0000390 1.0000277 0.9999878)
	0.0001	7	(0.9999929 0.9999949 1.0000022)
	0.00001	9	(0.9999998 0.9999998 1.0000001)
Jacobi	0.001	9	(1.0002507 1.0000694 1.0002507)
	0.0001	12	(1.0000102 0.9999835 1.0000102)
	0.00001	14	(0.9999981 1.0000020 0.9999981)

# 目录

- 1 Jacobi 迭代法与 Gauss-Seidel 迭代法
- 2 Jacobi 迭代与 Gauss-Seidel 迭代的收敛性分析
- 3 超松弛迭代法
- 4 共轭梯度法
- 5 非线性方程组的迭代解法

## §7.2.1 收敛的充分必要条件及误差估计

如前所述, Jacobi 迭代与 Gauss-Seidel 迭代都可以写成如下统一的形式

$$x^{(k+1)} = Mx^{(k)} + g, \quad k = 0, 1, \dots$$

此格式称为**单步定常线性迭代法**. 当迭代产生的序列  $\{x^{(k)}\}_{k=0}^{\infty}$  收敛到向量  $x^*$ , 则称迭代算法收敛, 否则称为不收敛或发散.

### 问题

若迭代序列收敛, 则

$$x^* = Mx^* + g \iff Ax^* = b(???)$$

## 定义 (相容性)

如果方程组  $Ax = b$  与  $x = Mx + g$  等价, 即存在可逆矩阵  $G$  使得

$$G(I - M) = A, \quad Gg = b$$

则称迭代法  $x^{(k+1)} = Mx^{(k)} + g$  与已知方程组是相容的.

- Jacobi 迭代法:

$$M = D^{-1}(L + U) = I - D^{-1}A \Rightarrow D(I - M) = A$$

- Gauss-Seidel 迭代法:

$$M = (D - L)^{-1}U \Rightarrow (D - L)(I - M) = A$$

## 引理 (收敛的充分必要条件)

迭代算法  $x^{(k+1)} = Mx^{(k)} + g$  收敛的充要条件是  $M^k \rightarrow 0$ .

证明: 假设迭代算法收敛, 则有

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \Rightarrow x^* = Mx^* + g$$

设  $x^*$  为  $Ax = b$  的解, 由相容性可知

$$Ax^* = b \Leftrightarrow x^* = Mx^* + g$$

从而可知

$$x^{(k)} - x^* = M(x^{(k-1)} - x^*) = \cdots = M^k(x^{(0)} - x^*)$$

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \Leftrightarrow M^k \rightarrow 0.$$



## 定理 (充分必要条件)

迭代算法  $x^{(k+1)} = Mx^{(k)} + g$  收敛的充要条件是  $M$  的谱半径满足  $\rho(M) < 1$ .

## 注释

- 迭代法是否收敛取决于迭代矩阵的谱半径，与初始向量和常数项无关。
- 而对于同一个方程组，不同的迭代法对应的迭代矩阵的谱半径一般不会相同，因而收敛性也不同。

例如：若方程组系数矩阵满足

$$A_1 = \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix}, \quad A_2 = \begin{bmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{bmatrix}$$

Jacobi 迭代法,  $JM = D^{-1}(L + U)$ , Gauss-Seidel 迭代法,  $GM = (D - L)^{-1}U$ .

对于  $A_1$  来说,

$$\rho(JM) = 0 < 1, \Rightarrow \text{Jacobi 迭代法收敛}$$

$$\rho(GM) = 2 > 1, \Rightarrow \text{Gauss-Seidel 迭代法不收敛}$$

对于  $A_2$  来说,

$$\rho(JM) = \sqrt{5}/2 > 1, \Rightarrow \text{Jacobi 迭代法不收敛}$$

$$\rho(GM) = \frac{1}{2} < 1, \Rightarrow \text{Gauss-Seidel 迭代法收敛}$$

## 注释

实际应用中，计算谱半径较为困难，因此判断迭代过程是否收敛需要考虑更易操作的条件.

## 定理 (误差估计 I)

若迭代矩阵  $\|M\| = q < 1$ , 并假定范数  $\|I\| = 1$ , 则迭代算法  $x^{(k+1)} = Mx^{(k)} + g$  收敛, 且其误差满足

$$\|x^{(k)} - x^*\| \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|.$$

证明:

$$\begin{aligned} x^{(k)} - x^* &= M^k(x^{(0)} - x^*) \\ \Rightarrow \|x^{(k)} - x^*\| &\leq \|M^k(x^{(0)} - x^*)\| \leq q^k \|x^{(0)} - x^*\| \end{aligned}$$

注意到

$$\begin{aligned}
 x^{(0)} - x^* &= x^{(0)} - (I - M)^{-1}g = (I - M)^{-1}((I - M)x^{(0)} - g) \\
 &= (I - M)^{-1}(x^{(0)} - Mx^{(0)} - g) = (I - M)^{-1}(x^{(0)} - x^{(1)})
 \end{aligned}$$

由

$$\|(I - M)^{-1}\| \leq \frac{1}{1 - \|M\|} = \frac{1}{1 - q},$$

所以

$$\|x^{(k)} - x^*\| \leq q^k \|(I - M)^{-1}(x^{(0)} - x^{(1)})\| \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|.$$

## 注释

- 利用矩阵的范数判定迭代收敛只是一个充分条件，通常采用矩阵的 1-范数、 $\infty$ -范数来判定。
- 由上定理可知，可计算满足精度要求的近似解需要迭代次数。但此方法估计往往偏高，实际计算应用不便。

## 定理 (误差估计 II)

若迭代矩阵  $\|M\| = q < 1$ , 并假定范数  $\|I\| = 1$ , 则迭代算法  $x^{(k+1)} = Mx^{(k)} + g$  收敛, 且其误差满足

$$\|x^{(k)} - x^*\| \leq \frac{q}{1 - q} \|x^{(k)} - x^{(k-1)}\|.$$

证明:

$$\begin{aligned} x^{(k)} - x^* &= Mx^{(k-1)} + g - (Mx^* + g) \\ &= Mx^{(k-1)} - Mx^* \\ &= Mx^{(k-1)} - M(I - M)^{-1}g \\ &= M(I - M)^{-1}(x^{(k-1)} - Mx^{(k-1)} - g) \\ &= M(I - M)^{-1}(x^{(k-1)} - x^{(k)}) \end{aligned}$$

两边取范数得结论.

## 定理 (收敛的充分条件 I)

设  $B$  是 *Jacobi* 迭代的迭代矩阵, 若  $\|B\|_{\infty} < 1$ , 则 *Gauss-Seidel* 迭代算法收敛, 且满足估计

$$\|x^{(k)} - x^*\|_{\infty} \leq \frac{\mu^k}{1 - \mu} \|x^{(1)} - x^{(0)}\|_{\infty}$$

其中

$$\mu = \max_i \left( \sum_{j=i+1}^n |b_{ij}| / \left( 1 - \sum_{j=1}^{i-1} |b_{ij}| \right) \right)$$

且有  $\mu \leq \|B\|_{\infty} < 1$ , 这里  $b_{ij}$  是矩阵  $B$  的元素.



## 定理 (收敛的充分条件 II)

设  $B$  是 *Jacobi* 迭代的迭代矩阵, 若  $\|B\|_1 < 1$ , 则 *Gauss-Seidel* 迭代算法收敛, 且满足估计

$$\|x^{(k)} - x^*\|_\infty \leq \frac{\tilde{\mu}^k}{(1 - \tilde{\mu})(1 - s)} \|x^{(1)} - x^{(0)}\|_\infty$$

其中

$$s = \max_j \sum_{i=j+1}^n |b_{ij}|, \quad \tilde{\mu} = \max_j \left( \sum_{i=1}^{j-1} |b_{ij}| / (1 - \sum_{i=j+1}^n |b_{ij}|) \right) \leq \|B\|_1 < 1.$$

## 定理 (Jacobi 迭代收敛的充要条件)

若系数矩阵  $A$  对称, 对角线元素  $a_{ii} > 0 (i = 1, 2, \dots, n)$ , 则 Jacobi 迭代算法收敛的充分必要条件是  $A$  和  $2D - A$  都正定.

证明: 对于 Jacobi 迭代算法, 其迭代矩阵

$$B = I - D^{-1}A = D^{-1/2}(I - D^{-1/2}AD^{-1/2})D^{1/2}$$

故矩阵  $B$  与  $I - D^{-1/2}AD^{-1/2}$  相似, 故有相同的特征值; 且  $D^{-1/2}AD^{-1/2}$ ,  $I - D^{-1/2}AD^{-1/2}$ ,  $2I - D^{-1/2}AD^{-1/2}$  对称.

必要性. 假设 Jacobi 迭代算法收敛, 即  $\rho(B) < 1$ , 则矩阵  $I - D^{-1/2}AD^{-1/2}$  特征值绝对值小于 1, 即  $D^{-1/2}AD^{-1/2}$  的特征值介于  $(0, 2)$  之间, 从而  $A$  正定. 另外  $2I - D^{-1/2}AD^{-1/2}$  的特征值也全为正数, 所以  $2I - D^{-1/2}AD^{-1/2}$  也正定.

而

$$D^{-1/2}(2D - A)D^{-1/2} = 2I - D^{-1/2}AD^{-1/2}$$

因此  $2D - A$  都正定.

充分性. 因

$$D^{-1/2}AD^{-1/2} = D^{1/2}(I - B)AD^{-1/2}$$

由  $A$  正定, 可知  $I - B$  的特征值全大于零, 所以  $B$  的特征值均小于 1. 因为  $2D - A$  正定, 又

$$D^{-1/2}(2D - A)D^{-1/2} = D^{1/2}(I + B)D^{-1/2}$$

故  $I + B$  的特征值均大于零,  $B$  的特征值均大于 -1, 从而  $\rho(B) < 1$ , Jacobi 迭代法收敛.

## 定理

若系数矩阵  $A$  对称正定, 则 *Gauss-Seidel* 迭代收敛.

证明: 设  $\lambda$  为 Gauss-Seidel 迭代矩阵  $(D - L)^{-1}U$  的一个特征值,  $v$  为对于特征向量, 则有

$$(D - L)^{-1}Uv = \lambda v \Rightarrow Uv = L^T v = \lambda(D - L)v \Rightarrow v^* L^T v = \lambda v^* Dv - \lambda v^* Lv$$

令  $\delta = v^* Dv$ ,  $v^* Lv = \alpha + i\beta$ , 则有

$$\begin{aligned} v^* L^T v &= \alpha - i\beta \\ \Rightarrow \lambda(\delta - (\alpha + i\beta)) &= \alpha - i\beta \\ \Rightarrow \lambda^2((\delta - \alpha)^2 + \beta^2) &= \alpha^2 + \beta^2 \\ \Rightarrow \lambda^2 &= \frac{\alpha^2 + \beta^2}{(\delta - \alpha)^2 + \beta^2} \end{aligned}$$

因

$$0 < v^* A v = v^* (D - L - L^T) v = \delta - 2\alpha$$

从而可知

$$(\delta - \alpha)^2 + \beta^2 = \alpha^2 + \beta^2 + \delta(\delta - 2\alpha) > \alpha^2 + \beta^2$$

也即是

$$|\lambda| < 1.$$

## 注释

从上面定理可知，迭代算法收敛性的判别，可由方程系数矩阵性质来判别。

## 定义 (对角占优矩阵)

设矩阵  $A \in R^{n \times n}$ , 若对所有的  $1 \leq i \leq n$  都有

$$|a_{ii}| \geq \sum_{j=1, j \neq i}^n |a_{ij}|$$

并且上不等式至少对一个  $i$  有严格不等号成立, 则称矩阵  $A$  为弱严格 (行) 对角占优的; 若对所有的  $i$  都有严格不等式成立, 则称矩阵  $A$  为严格 (行) 对角占优的或强对角占优的.

## 定义 (可约矩阵)

如果存在  $n$  阶排列矩阵  $P$ , 使

$$PAP^T = \begin{bmatrix} A_{11} & 0 \\ A_{21} & A_{22} \end{bmatrix} \quad (2.8)$$

$A_{11}$  为  $r$  阶方阵,  $A_{22}$  为  $n - r$  阶方阵, 则称  $A$  可约 (可分); 反之, 如果不存在这样的排列矩阵, 则称  $A$  不可约.

例如: 下面矩阵  $A$  可约

$$A = \begin{bmatrix} -1 & 1 & 2 \\ 0 & 0 & 1 \\ 0 & -1 & 1 \end{bmatrix} \Rightarrow \begin{bmatrix} 0 & -1 & 1 \\ 0 & 0 & 1 \\ -1 & 1 & 2 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & -1 & 0 \\ 1 & 0 & 0 \\ 2 & 1 & -1 \end{bmatrix}$$

## 注释

若系数矩阵  $A$  是可约的, 则可通过行与列重排化为上面 (2.8) 式, 从而可将方程组简化为低阶方程组。  $A_{11}x_1 = b_1, A_{22}x_2 = b_2 - A_{21}x_1$

## 定义 (不可约对角占优)

若一个矩阵不可约, 且弱严格对角占优, 则称为不可约对角占优矩阵。

## 定理

若  $A$  是严格对角占优或不可约对角占优矩阵, 则  $A$  非奇异的。

## 推论

若  $A$  是严格对角占优或不可约对角占优的对称矩阵, 且对角线元素皆正, 则  $A$  正定。



## 定理

若  $A$  是严格对角占优或不可约对角占优的矩阵, 则 *Jacobi* 迭代和 *Gauss-Seidel* 迭代收敛.

证明: 先证明 Jacobi 迭代收敛. 反证法. 因  $A$  是严格对角占优或不可约对角占优, 则有  $|a_{ii}| > 0$ , 故  $D$  可逆. 现假设 Jacobi 迭代矩阵  $B$  的某个特征值  $|\lambda| \geq 1$ , 考察矩阵  $\lambda D - L - U$ , 显然  $\lambda D - L - U$  也是严格对角占优或不可约对角占优的, 因此  $\lambda D - L - U$  非奇异. 再由

$$\begin{aligned}\lambda I - B &= \lambda I - D^{-1}(L + U) \\ &= D^{-1}(\lambda D - L - U)\end{aligned}$$

可推得

$$\det(\lambda I - B) = \det(D^{-1})\det(\lambda D - L - U) \neq 0$$

这与  $\lambda$  是  $B$  的特征值矛盾. 即 Jacobi 迭代矩阵  $B$  的所有特征值绝对值均小于 1, 故 Jacobi 迭代收敛.

关于 Gauss-Seidel 迭代, 只需要考虑矩阵  $\lambda D - \lambda L - U$ , 用同样的方法可证明  $(D - L)^{-1}U$  的特征值的模均小于 1, 即 Gauss-Seidel 迭代收敛.

# 收敛速度

一般的迭代格式为

$$x^{(k+1)} = Mx^{(k)} + g$$

通常用  $\|M^k\|$  的大小来反映迭代算法的收敛速度.

## 定义 (平均收敛速度)

定义

$$R_k(M) = -\frac{\ln \|M^k\|}{k} = -\ln \|M^k\|^{\frac{1}{k}}$$

为  $k$  次迭代的平均收敛速度.

## 定义 (渐进收敛速度)

定义

$$R(M) = -\ln \rho(M)$$

为迭代算法的渐进收敛速度.

# 目 录

- 1 Jacobi 迭代法与 Gauss-Seidel 迭代法
- 2 Jacobi 迭代与 Gauss-Seidel 迭代的收敛性分析
- 3 超松弛迭代法**
- 4 共轭梯度法
- 5 非线性方程组的迭代解法

## §7.3.1 超松弛迭代法概述

超松弛迭代法思想：类似于 G-S 迭代的改进方法，利用  $k$  次迭代值与  $k+1$  次的 G-S 迭代值做加权平均。

由前面的知识可知，G-S 迭代算法

$$\bar{x}_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right), \quad i = 0, 1, 2, \dots, n \quad (3.9)$$

做加权平均

$$x_i^{(k+1)} = \omega \bar{x}_i^{(k+1)} + (1 - \omega) x_i^{(k)}$$

即得超松弛迭代法的分量形式

超松弛 (SOR) 迭代法:

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \omega \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right) \quad (3.10)$$

其中  $\omega$  称为松弛因子;  $\omega = 1$  时即为 G-S 迭代法. 记  $A = D - L - U$ , 则超松弛 (SOR) 迭代法的矩阵形式为

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega D^{-1}(b + Lx^{(k+1)} + Ux^{(k)}) \quad (3.11)$$

或者

$$x^{(k+1)} = Sx^{(k)} + g, \quad g = \omega(D - \omega L)^{-1}b \quad (3.12)$$

迭代矩阵  $S = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$ .

例：写出 SOR 迭代法求解下列方程组的迭代格式

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix}$$

解：SOR 迭代公式为

$$\begin{aligned} x_1^{(k+1)} &= (1 - \omega)x_1^{(k)} + \frac{\omega}{4}(24 - 3x_2^{(k)}) \\ x_2^{(k+1)} &= (1 - \omega)x_2^{(k)} + \frac{\omega}{4}(30 - 3x_1^{(k+1)} + x_3^{(k)}) \\ x_3^{(k+1)} &= (1 - \omega)x_3^{(k)} + \frac{\omega}{4}(-24 + x_2^{(k+1)}) \end{aligned}$$

若取初值  $x^{(0)} = (1, 1, 1)^T$ ，选取不同的  $\omega$  值计算，结果如下表



$\omega$	Tol	迭代次数	近似解
$\omega = 1$	0.001	12	(3.0012790 3.9989342 -5.0002665)
	0.0001	16	(3.0001952 3.9998374 -5.0000407)
	0.00001	21	(3.0000186 3.9999845 -5.0000039)
$\omega = 0.95$	0.001	12	(3.0020191 3.9982705 -5.0004444)
	0.0001	18	(3.0001673 3.9998567 -5.0000368)
	0.00001	23	(3.0000210 3.9999820 -5.0000046)
$\omega = 1.25$	0.001	8	(2.9997451 4.0000653 -4.9998924)
	0.0001	10	(2.9999853 4.0000031 -4.9999935)
	0.00001	12	(2.9999993 4.0000001 -4.9999996)
$\omega = 1.5$	0.001	13	(3.0006104 4.0001741 -5.0007434)
$\omega = 1.95$	0.001	151	(2.9995106 4.0017780 -5.0027919)

# 其他格式

- 向后超松弛 (BSOR) 迭代格式

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega D^{-1}(b + Lx^{(k)} + Ux^{(k+1)}) \quad (3.13)$$

- 对称超松弛 (SSOR) 迭代格式

$$\begin{aligned}\bar{x}^{(k+1)} &= (1 - \omega)x^{(k)} + \omega D^{-1}(b + Lx^{(k+1)} + Ux^{(k)}) \\ x^{(k+1)} &= (1 - \omega)\bar{x}^{(k)} + \omega D^{-1}(b + L\bar{x}^{(k)} + Ux^{(k+1)})\end{aligned}$$

例：写出 BSOR 及 SSOR 迭代法求解下列方程组的迭代格式

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix}$$

解：BSOR 迭代公式为

$$\begin{aligned}x_3^{(k+1)} &= (1 - \omega)x_3^{(k)} + \frac{\omega}{4}(-24 + x_2^{(k)}) \\x_2^{(k+1)} &= (1 - \omega)x_2^{(k)} + \frac{\omega}{4}(30 - 3x_1^{(k)} + x_3^{(k+1)}) \\x_1^{(k+1)} &= (1 - \omega)x_1^{(k)} + \frac{\omega}{4}(24 - 3x_2^{(k+1)})\end{aligned}$$

SSOR 迭代公式为

$$\begin{aligned}\bar{x}_1^{(k+1)} &= (1 - \omega)x_1^{(k)} + \frac{\omega}{4}(24 - 3x_2^{(k)}) \\\bar{x}_2^{(k+1)} &= (1 - \omega)x_2^{(k)} + \frac{\omega}{4}(30 - 3\bar{x}_1^{(k+1)} + x_3^{(k)}) \\\bar{x}_3^{(k+1)} &= (1 - \omega)x_3^{(k)} + \frac{\omega}{4}(-24 + \bar{x}_2^{(k+1)})\end{aligned}$$

$$\begin{aligned}
x_3^{(k+1)} &= (1 - \omega)\bar{x}_3^{(k)} + \frac{\omega}{4}(-24 + \bar{x}_2^{(k)}) \\
x_2^{(k+1)} &= (1 - \omega)\bar{x}_2^{(k)} + \frac{\omega}{4}(30 - 3\bar{x}_1^{(k)} + x_3^{(k+1)}) \\
x_1^{(k+1)} &= (1 - \omega)\bar{x}_1^{(k)} + \frac{\omega}{4}(24 - 3x_2^{(k+1)})
\end{aligned}$$

若取初值  $x^{(0)} = (1, 1, 1)^T$ , 选取  $\omega = 1.25$  进行计算, 结果如下表

所用方法	Tol	迭代次数	近似解
BSOR	0.001	8	(2.9998426 4.0003635 -4.9995660)
	0.0001	10	(2.9999991 4.0000051 -4.9999831)
	0.00001	11	(3.0000012 3.9999988 -5.0000027)
SSOR	0.001	18	(3.0008900 3.9985916 -5.0003161)
	0.0001	23	(3.0000939 3.9998514 -5.0000334)
	0.00001	28	(3.0000099 3.9999843 -5.0000035)

# 举例

考虑前面的问题

# 举例

考虑前面的问题

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix}$$

# 举例

考虑前面的问题

$$\begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 24 \\ 30 \\ -24 \end{bmatrix}$$

从而可知系数矩阵  $A$  及其 Jacobi 迭代矩阵  $B$

$$A = \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & -3/4 & 0 \\ -3/4 & 0 & 1/4 \\ 0 & 1/4 & 0 \end{bmatrix}.$$

不难看出, 矩阵  $A$  是对称正定的三对角矩阵, 可以用定理结论. 可计算出

$$\rho(B) = \sqrt{0.625} \approx 0.790, \quad \rho(G - S) = 0.625.$$

而 SOR 方法的最优松弛因子

$$\omega_b = \frac{2}{1 - \sqrt{1 - 0.625}} \approx 1.24,$$

从而可得

$$\rho(S_{\omega_b}) \approx 0.24 < \rho(G - S) < \rho(B).$$

显然, 可知采用最优松弛因子的 SOR 法比 G-S 方法和 Jacobi 方法收敛的快得多.



## §7.3.2 SOR 迭代格式的收敛性

### 定理

对任意的矩阵  $A \in R^{n \times n}$ , 设其对角线元皆非零, 则对所有实数  $\omega$ , 有  $\rho(S) \geq |\omega - 1|$ , 其中  $S = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$ .

证明: 令  $A = D - L - U$ . 设迭代矩阵  $S$  的特征值为  $\lambda_1, \dots, \lambda_n$

$$\begin{aligned} \det(S) &= \lambda_1 \cdots \lambda_n \\ \det(S) &= \det(D - \omega L)^{-1} \det([(1 - \omega)D + \omega U]) \\ &= \det D^{-1} \det[(1 - \omega)D] = (1 - \omega)^n \\ \Rightarrow |1 - \omega|^n &\leq |\lambda_1| \cdots |\lambda_n| \leq (\max_i |\lambda_i|)^n \\ \Rightarrow |\omega - 1| &\leq \rho(S) \end{aligned}$$

## 推论

如果  $Ax = b$  的  $SOR$  迭代收敛, 则

$$|\omega - 1| < 1 \quad or \quad 0 < \omega < 2.$$

## 定理

对任意的矩阵  $A \in R^{n \times n}$  为对称正定矩阵, 且  $0 < \omega < 2$ , 则解线性方程组  $Ax = b$  的  $SOR$  迭代收敛.

证明: 记  $A = D - L - U$ . 因矩阵  $A$  对称正定, 则  $A^T = A, L^T = U$ ,  $SOR$  迭代矩阵为

$$S = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$$

设  $SOR$  迭代矩阵的任意特征值为  $\lambda$ , 其相应的特征向量为  $x$ , 则

$$Sx = \lambda x \Rightarrow [(1 - \omega)D + \omega U]x = \lambda(D - \omega L)x$$

上式两边与  $x$  做内积

$$(1 - \omega)(Dx, x) + \omega(Ux, x) = \lambda[(Dx, x) - \omega(Lx, x)] \quad (3.14)$$

因  $A$  正定, 故可知  $D$  正定, 从而可知  $p = (Dx, x) > 0$ . 记  $(Lx, x) = \alpha + i\beta$ , 则取共轭复数有  $(Ux, x) = \alpha - i\beta$ , 代入 (3.14), 可以求得特征值

$$\lambda = \frac{(1 - \omega)p + \omega\alpha - i\omega\beta}{p - \omega\alpha - i\omega\beta}, \quad |\lambda|^2 = \frac{[p - (\omega p - \alpha)]^2 + \omega^2\beta^2}{(p - \omega\alpha)^2 + \omega^2\beta^2}$$

注意到上面分子减分母

$$[p - (\omega p - \alpha)]^2 - (p - \omega\alpha)^2 = p\omega(2 - \omega)(2\alpha - p).$$

因为  $A$  正定,

$$(Ax, x) = (Dx, x) - (Lx, x) - (Ux, x) = p - 2\alpha > 0$$

利用  $0 < \omega < 2$ , 可知  $|\lambda|^2 < 1$ , 从而 SOR 迭代法收敛.

## 定理

设矩阵  $A \in R^{n \times n}$  对称, 其对角线元  $a_{ii} > 0$ , 若求解方程组  $Ax = b$  的  $SOR$  迭代法收敛, 则  $A$  正定, 且  $0 < \omega < 2$ .

证明: 记第  $k$  次的迭代误差向量为

$$e^{(k)} = x^{(k)} - x^*, \quad \delta^{(k)} = e^{(k)} - e^{(k+1)} = x^{(k)} - x^{(k+1)}.$$

由  $SOR$  迭代算法可知  $e^{(k+1)} = Se^{(k)}$ , 从而可得

$$\begin{aligned}(D - \omega L)e^{(k+1)} &= [(1 - \omega)D + \omega U]e^{(k)} \\&= (D - \omega L)e^{(k)} - \omega(D - L - U)e^{(k)} \\&= (D - \omega L)e^{(k)} - \omega Ae^{(k)} \\ \Rightarrow (D - \omega L)\delta^{(k)} &= \omega Ae^{(k)}\end{aligned}$$

## 考察二次型

$$\begin{aligned}(Ae^{(k+1)}, e^{(k+1)}) &= (A(e^{(k)} - \delta^{(k)}), e^{(k)} - \delta^{(k)}) \\ &= (Ae^{(k)}, e^{(k)}) - 2(Ae^{(k)}, \delta^{(k)}) + (A\delta^{(k)}, \delta^{(k)})\end{aligned}$$

注意到  $L^T = U$ , 所以  $((L - U)\delta^{(k)}, \delta^{(k)}) = 0$ , 所以

$$\begin{aligned}& \omega[(Ae^{(k)}, e^{(k)}) - (Ae^{(k+1)}, e^{(k+1)})] \\ &= 2\omega(Ae^{(k)}, \delta^{(k)}) - \omega(A\delta^{(k)}, \delta^{(k)}) \\ &= 2((D - \omega L)\delta^{(k)}, \delta^{(k)}) - \omega(A\delta^{(k)}, \delta^{(k)}) \\ &= ((2D - \omega L - \omega D + \omega L + \omega U)\delta^{(k)}, \delta^{(k)}) \\ &= (2 - \omega)(D\delta^{(k)}, \delta^{(k)})\end{aligned}$$

因SOR算法收敛, 故而  $0 < \omega < 2$ , 又  $a_{ii} > 0$ , 从而可知

$$(2 - \omega)(D\delta^{(k)}, \delta^{(k)}) > 0 \Rightarrow (Ae^{(k)}, e^{(k)}) > (Ae^{(k+1)}, e^{(k+1)})$$

说明上面的二次型单调递减趋于零. 若矩阵  $A$  不正定, 则存在非零向量  $e^{(0)}$  使得

$$(Ae^{(0)}, e^{(0)}) \leq 0$$

且有  $\delta^{(0)} = e^{(0)} - e^{(1)} = (I - S)e^{(0)} \neq 0$

$$(Ae^{(1)}, e^{(1)}) < (Ae^{(0)}, e^{(0)}) \leq 0$$

这与二次型单调递减趋于零矛盾.

### 定理 (SSOR 迭代法的收敛性)

设矩阵  $A \in R^{n \times n}$  对称正定, 且  $0 < \omega < 2$ , 则解方程组  $Ax = b$  的 SSOR 迭代法收敛.

### §7.3.3 最佳松弛因子

#### 定义 (2-循环矩阵)

设矩阵  $A \in R^{n \times n}$ ,  $A = D - L - U$ . 若存在排列矩阵  $P$  使得

$$PAP^T = \begin{bmatrix} D_1 & M_1 \\ M_2 & D_2 \end{bmatrix}$$

其中  $D_1, D_2$  为对角阵, 则称矩阵  $A$  为 2-循环矩阵.

#### 定义 (相容次序矩阵)

设矩阵  $A \in R^{n \times n}$ ,  $A = D - L - U$ . 若  $\alpha \neq 0$  时,  $\alpha D^{-1}L + \alpha^{-1}D^{-1}U$  的特征值都与  $\alpha$  无关, 则称矩阵  $A$  为相容次序矩阵.

## 定理

设矩阵  $A \in R^{n \times n}$  的所有对角元非零, 且是 2-循环矩阵和相容次序矩阵, 记  $B = D^{-1}(L + U)$  为求解线性方程组  $Ax = b$  的 *Jacobi* 迭代矩阵, 且  $B^2$  的特征值均在  $[0, 1)$  上; 并记

$$\mu = \rho(B) \quad \omega_b = \frac{2}{1 + \sqrt{1 - \mu^2}}$$

则求解方程组  $Ax = b$  的 *SOR* 迭代法的迭代矩阵  $S$  的谱半径满足

$$\rho(S) = \begin{cases} \frac{(\omega\mu + \sqrt{\omega^2\mu^2 - 4(\omega-1)^2})^2}{4} & 0 < \omega < \omega_b \\ \omega - 1 & \omega_b \leq \omega \leq 2 \end{cases}$$

$$\rho(S_{\omega_b}) = \min_{0 \leq \omega \leq 2} \rho(S_{\omega})$$

且当  $0 < \omega < \omega_b$  时,  $\rho(S_{\omega})$  是  $\omega$  的单调递减函数, 并有




$$\lim_{\omega \rightarrow \omega_b} \frac{d}{d\omega} \rho(S_\omega) = -\infty.$$

## 注释

关于最佳松弛因子的进一步讨论，可参考文献《数值计算方法》（下册），林成森著，《矩阵迭代分析》，R.S.Varga 著，蒋尔雄等译。

## 谱半径与松弛因子关系图



# 知识小结

## Jacobi、Gauss-Seidel、SOR 迭代算法收敛性判别

算法	收敛性条件
Jacobi 迭代 $B = D^{-1}(L + U)$	$\rho(B) < 1$ $A, 2D - A$ 对称正定 $a_{ii} > 0$ $A$ 严格对角占优或不可约对角占优
G-S 迭代 $GS = (D - L)^{-1}U$	$\rho(GS) < 1$ Jacobi 迭代矩阵 $\ B\ _1 < 1$ Jacobi 迭代矩阵 $\ B\ _\infty < 1$ $A$ 对称正定 $A$ 严格对角占优或不可约对角占优
SOR 迭代 $S = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$	$A$ 对称正定且 $0 < \omega < 2$

# 目 录

- 1 Jacobi 迭代法与 Gauss-Seidel 迭代法
- 2 Jacobi 迭代与 Gauss-Seidel 迭代的收敛性分析
- 3 超松弛迭代法
- 4 共轭梯度法**
- 5 非线性方程组的迭代解法

共轭梯度法 (Conjugate Gradient Methods) 是一种求解对称正定线性方程组的方法.

它是 20 世纪 50 年代初期 Hestenes 和 Stiefel 首先提出.

它是一种变分方法, 其思想是将求解方程组问题等价转化为一个二次泛函的极值问题.

## §7.4.1 最速下降法

考虑如下的线性方程组

$$Ax = b, \quad A \text{ 对称正定}, x = (x_1, \dots, x_n)^T, \quad b = (b_1, \dots, b_n)^T$$

为了说明最速下降法的思想, 定义二次型

$$\varphi(x) = (Ax, x) - 2(b, x) = x^T Ax - 2b^T x.$$

此二次型有如下性质:

- ① 对任意的  $x \in R^n$ ,  $\nabla \varphi(x) = 2(Ax - b)$ ;
- ② 设  $x^* = A^{-1}b$  为  $Ax = b$  的解, 则

$$\varphi(x^*) = -(Ax^*, x^*)$$

$$\begin{aligned}
 \varphi(x) - \varphi(x^*) &= (Ax, x) - 2(b, x) + (Ax^*, x^*) \\
 &= (Ax, x) - 2(Ax^*, x) + (Ax^*, x^*) \\
 &= (A(x - x^*), x - x^*)
 \end{aligned}$$

## 定理

设矩阵  $A$  对称正定，则求线性方程组  $Ax = b$  等价于求二次型  $\varphi(x)$  的极小值点


$$\varphi(x^*) = \min_{x \in R^n} \varphi(x)$$

证明：必要性. 由二次型的性质可以直接得到. 下面证明充分性. 如果  $\varphi(x^*) = \min_{x \in R^n} \varphi(x)$ , 则由极值的必要条件得  $\nabla \varphi(x^*) = 2(Ax^* - b) = 0$ , 从而  $Ax^* = b$ .

## 最速下降法的思想

最速下降法是指每次沿着函数值下降最快的方向寻找最小值点. 而函数值下降最快的方向是函数的负梯度方向.

其几何意义如下图所示



# 最速下降法的实现过程

选取初始向量  $x^{(0)}$ ，由二次泛函  $\varphi(x)$  的基本性质 (1)

$$-\nabla\varphi(x^{(0)})/2 = b - Ax^{(0)} =: r^{(0)}$$

如果  $r^{(0)} = 0$ ，则  $x^{(0)}$  为方程组的解；如果  $r^{(0)} \neq 0$ ，则沿  $r^{(0)}$  方向进行一维极小搜索：求步长  $\alpha$  使得

$$\min_{\alpha} \varphi(x^{(0)} + \alpha r^{(0)})$$

由

$$\frac{d}{d\alpha} \varphi(x^{(0)} + \alpha r^{(0)}) = 0$$

$$\Rightarrow 2\alpha(Ar^{(0)}, r^{(0)}) - 2(r^{(0)}, r^{(0)}) = 0 \quad \Rightarrow \alpha_0 = \frac{(r^{(0)}, r^{(0)})}{(Ar^{(0)}, r^{(0)})}$$



令  $x^{(1)} = x^{(0)} + \alpha_0 r^{(0)}$ , 完成第一次迭代; 依次类推, 重复上述过程.

## 最速下降法的算法

选取初始向量  $x^{(0)}$ , 计算  
 $r^{(0)} = b - Ax^{(0)}$ ;  $k = 0$ ;

while  $r^{(0)} < \varepsilon$

$k = k + 1$ ;

$\alpha_{k-1} = \frac{(r^{(k-1)}, r^{(k-1)})}{(Ar^{(k-1)}, r^{(k-1)})}$ ;

$x^{(k)} = x^{(k-1)} + \alpha_{k-1} r^{(k-1)}$ ;

$r^{(k)} = b - Ax^{(k)}$ ;

end

搜索方向是正交的:

$$(r^{(k+1)}, r^{(k)}) = 0$$

注意到

$$\begin{aligned} r^{(k+1)} &= b - Ax^{(k+1)} \\ &= b - A(x^{(k)} + \alpha_k r^{(k)}) \\ &= r^{(k)} - \alpha_k Ar^{(k)} \end{aligned}$$

缺陷: 收敛速度慢.

## 引理

设矩阵  $A$  的特征值为  $0 < \lambda_1 \leq \cdots \leq \lambda_n$ ,  $P(t)$  是关于  $t$  的一个实系数多项式, 则

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \|x\|_A, \quad x \in R^n$$

其中  $\|x\|_A = \sqrt{x^T A x}$

证明: 设  $Ay_i = \lambda_i y_i$ , 且满足

$$(y_i, y_j) = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

则对任意的  $x$ ,  $x = \sum_{i=1}^n \beta_i y_i$

所以

$$\begin{aligned}(P(A)x)^T A P(A)x &= \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i\right)^T A \left(\sum_{i=1}^n \beta_i P(\lambda_i) y_i\right) \\&= \sum_{i=1}^n \lambda_i \beta_i^2 P^2(\lambda_i) \\&\leq \max_{1 \leq i \leq n} P^2(\lambda_i) \sum_{i=1}^n \lambda_i \beta_i^2 \\&= \max_{1 \leq i \leq n} P^2(\lambda_i) x^T A x\end{aligned}$$

从而可得

$$\|P(A)x\|_A \leq \max_{1 \leq i \leq n} |P(\lambda_i)| \|x\|_A$$

## 定理 (最速下降法的收敛性定理)

设矩阵  $A$  的特征值为  $0 < \lambda_1 \leq \cdots \leq \lambda_n$ , 则由最速下降法产生的迭代序列  $\{x^{(k)}\}$  满足

$$\|x^{(k)} - x^*\|_A \leq \left( \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^k \|x^{(0)} - x^*\|_A, \quad x^* = A^{-1}b.$$

证明: 由最速下降法思想可知

$$\varphi(x^{(k)}) \leq \varphi(x^{(k-1)} + \alpha r^{(k-1)})$$

又注意到

$$\begin{aligned} \varphi(x) + x^{*T} A x^* &= \varphi(x) - \varphi(x^*) \\ &= (x - x^*)^T A (x - x^*) \end{aligned}$$

$$\begin{aligned}
(x^{(k)} - x^*)^T A (x^{(k)} - x^*) &= \varphi(x^{(k)}) + x^{*T} A x^* \\
&\leq \varphi(x^{(k-1)} + \alpha r^{(k-1)}) + x^{*T} A x^* \\
&= (x^{(k-1)} + \alpha r^{(k-1)} - x^*)^T A (x^{(k-1)} + \alpha r^{(k-1)} - x^*) \\
(\textcolor{red}{r}^{(k-1)} = \textcolor{red}{b} - A x^{(k-1)}) &= [(I - \alpha A)(x^{(k-1)} - x^*)]^T A [(I - \alpha A)(x^{(k-1)} - x^*)]
\end{aligned}$$

记  $P_\alpha(t) = 1 - \alpha t$ , 则由引理可知

$$\|x^{(k)} - x^*\|_A \leq \|P_\alpha(A)(x^{(k-1)} - x^*)\|_A \leq \max_{1 \leq i \leq n} |P_\alpha(\lambda_i)| \|x^{(k-1)} - x^*\|_A$$

注意到

$$\begin{aligned}
\min_{\alpha} \max_{\lambda_1 \leq t \leq \lambda_n} |1 - \alpha t| &= \frac{\lambda_n - \lambda_1}{\lambda_1 + \lambda_n} \\
\Rightarrow \|x^{(k)} - x^*\|_A &\leq \frac{\lambda_n - \lambda_1}{\lambda_1 + \lambda_n} \|x^{(k-1)} - x^*\|_A.
\end{aligned}$$

## §7.4.2 共轭梯度法

### 备注

- 上定理告诉我们, 当  $\lambda_1 \ll \lambda_n$  时, 最速下降法收敛非常慢.
- 改进最速下降法, 得共轭梯度法.

### 定义 ( $A$ -共轭向量组)

设  $A \in R^{n \times n}$  为对称正定矩阵, 若  $R^n$  中向量组  $\{p^{(k)}\}_{k=1}^l$  满足  $(Ap^{(i)}, p^{(j)}) = 0, i \neq j$ , 则称其为  $R^n$  中一组  $A$ -共轭向量组.

### 共轭梯度法的思想

利用一维极小搜索方法确定一组  $A$ -共轭方向代替最速下降法中的正交方向来进行迭代.

# 共轭梯度法的实现过程


选取初始向量  $x^{(0)}$ , 第一步取负梯度方向下山, 即

$$\begin{aligned}p^{(0)} &= r^{(0)} = b - Ax^{(0)}, \\ \alpha^{(0)} &= \frac{(r^{(0)}, r^{(0)})}{(Ap^{(0)}, p^{(0)})}, \\ x^{(1)} &= x^{(0)} + \alpha^{(0)}p^{(0)}, \\ r^{(1)} &= b - Ax^{(1)},\end{aligned}$$

如何确定下一个搜索方向呢? 在过点  $x^{(1)}$  的由向量  $r^{(1)}$  和  $p^{(0)}$  所张成的下列二维平面内找出函数值下降最快的方向作为搜索方向  $p^{(1)}$

$$\pi_2 = \{x = x^{(1)} + \xi r^{(1)} + \eta p^{(0)} : \xi, \eta \in R\}$$

向量  $r^{(1)}$ ,  $p^{(0)}$  和  $p^{(1)}$  的几何意义



由此可知  $\varphi(x)$  在平面  $\pi_2$  可表示为

$$\begin{aligned}\varphi(x^{(1)} + \xi r^{(1)} + \eta p^{(0)}) &= (x^{(1)} + \xi r^{(1)} + \eta p^{(0)})^T A(x^{(1)} + \xi r^{(1)} + \eta p^{(0)}) \\ &\quad - 2b^T(x^{(1)} + \xi r^{(1)} + \eta p^{(0)}) \\ &= (A(x^{(1)} + \xi r^{(1)} + \eta p^{(0)}), (x^{(1)} + \xi r^{(1)} + \eta p^{(0)})) \\ &\quad - 2(b, (x^{(1)} + \xi r^{(1)} + \eta p^{(0)}))\end{aligned}$$

从而



$$\begin{aligned}
\frac{\partial \varphi}{\partial \xi} &= 2(A(x^{(1)} + \xi r^{(1)} + \eta p^{(0)}), r^{(1)}) - 2\xi(b, r^{(1)}) \\
&= 2[\xi(Ar^{(1)}, r^{(1)}) + \eta(Ap^{(0)}, r^{(1)}) - (r^{(1)}, r^{(1)})] = 0 \\
\frac{\partial \varphi}{\partial \eta} &= 2[\xi(Ar^{(1)}, p^{(0)}) + \eta(Ap^{(0)}, p^{(0)})] = 0
\end{aligned}$$

从而可得

$$\tilde{x} = x^{(1)} + \xi_0 r^{(1)} + \eta_0 p^{(0)},$$

其中  $\xi_0, \eta_0$  满足

$$\begin{aligned}
\xi_0(Ar^{(1)}, r^{(1)}) + \eta_0(Ap^{(0)}, r^{(1)}) &= (r^{(1)}, r^{(1)}) \\
\xi_0(Ar^{(1)}, p^{(0)}) + \eta_0(Ap^{(0)}, p^{(0)}) &= 0
\end{aligned}$$

取搜索方向  $p^{(1)}$  作为下一步下山方向

$$p^{(1)} = \frac{1}{\xi_0}(\tilde{x} - x^{(1)}) = r^{(1)} + \frac{\eta_0}{\xi_0}p^{(0)}$$

沿该方向进行一维搜索得步长为

$$\alpha_1 = \frac{(r^{(1)}, p^{(1)})}{(Ap^{(1)}, p^{(1)})}.$$

记

$$\begin{aligned}\beta_0 &= \frac{\eta_0}{\xi_0} = -\frac{(Ar^{(1)}, p^{(0)})}{(Ap^{(0)}, p^{(0)})} \\ x^{(2)} &= x^{(1)} + \alpha_1 p^{(1)}, \quad p^{(1)} = r^{(1)} + \beta_0 p^{(0)}\end{aligned}$$

重复上面过程，得到共轭梯度迭代序列.

# 一般计算公式

若已知  $p^{(k)}$ , 则第  $k + 1$  步迭代计算如下

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} &= b - Ax^{(k+1)} \\ \beta_k &= -\frac{(Ar^{(k+1)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} \\ p^{(k+1)} &= r^{(k+1)} + \beta_k p^{(k)}\end{aligned}$$

注意到

$$(r^{(k+1)}, p^{(k)}) = (b - Ax^{(k+1)}, p^{(k)}) = (r^{(k)}, p^{(k)}) - \alpha_k (Ap^{(k)}, p^{(k)}) = 0$$

$$(r^{(k)}, p^{(k)}) = (r^{(k)}, r^{(k)} + \beta_{k-1}p^{(k-1)}) = (r^{(k)}, r^{(k)})$$

从而

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})} \\ \beta_k &= -\frac{(r^{(k+1)}, Ap^{(k)})}{(Ap^{(k)}, p^{(k)})} = -\frac{(r^{(k+1)}, \alpha_k^{-1}(r^{(k)} - r^{(k+1)}))}{(Ap^{(k)}, p^{(k)})} \\ &= \alpha_k^{-1} \frac{(r^{(k+1)}, r^{(k+1)})}{(Ap^{(k)}, p^{(k)})} = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}\end{aligned}$$

# 算法

选取初始向量  $x^{(0)}$ , 计算  $p^{(0)} = r^{(0)} = b - Ax^{(0)}$ ,  $k = 0$   
while  $r^{(k)} \neq 0$

$$\begin{aligned}\alpha_k &= \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})} \\ x^{(k+1)} &= x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} &= r^{(k)} - \alpha_k Ap^{(k)} \\ \beta_k &= \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})} \\ p^{(k+1)} &= r^{(k+1)} + \beta_k p^{(k)} \\ k &= k + 1;\end{aligned}$$

end

## 定理

由共轭梯度法的序列  $\{r^{(i)}, p^{(i)}\}$  满足如下性质:

- (1)  $(r^{(j)}, p^{(i)}) = 0, \quad 0 \leq i < j \leq k;$
- (2)  $(r^{(j)}, r^{(i)}) = 0, \quad i \neq j, \quad 0 \leq i, j \leq k;$
- (3)  $(Ap^{(j)}, p^{(i)}) = 0, \quad i \neq j, \quad 0 \leq i, j \leq k;$
- (4)  $\text{span}\{r^{(0)}, \dots, r^{(k)}\} = \text{span}\{p^{(0)}, \dots, p^{(k)}\} =: K(A, r^{(0)}, k+1),$

其中

$$K(A, r^{(0)}, k+1) = \text{span}\{r^{(0)}, Ar^{(0)}, \dots, A^k r^{(0)}\}.$$

称为 *Krylov* 子空间.

## 注释

- 上面定理表明  $\{r^{(0)}, \dots, r^{(k)}\}$ ,  $\{p^{(0)}, \dots, p^{(k)}\}$  分别为 Krylov 子空间  $K(A, r^{(0)}, k+1)$  的正交基和共轭正交基.
- 共轭梯度法最多用  $n$  步便可得到方程组的精确解.
- 理论上讲, 共轭梯度法是直接算法.

## 定理

用共轭梯度法得到的近似解  $x^{(k)}$  满足

$$\varphi(x^{(k)}) = \min\{\varphi(x) : x \in x^{(0)} + K(A, r^{(0)}, k)\}$$

或

$$\|x^{(k)} - x^*\|_A = \min\{\|x^{(k)} - x^*\|_A : x \in x^{(0)} + K(A, r^{(0)}, k)\}.$$

# 例题

用 CG 方法求解下列方程组：  $x^{(0)} = (0, 0, 0)^T$

$$\begin{bmatrix} 2 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \\ 3 \end{bmatrix}$$

解：易证系数矩阵对称正定。

第一步：计算  $p^{(0)} = r^{(0)} = b - Ax^{(0)} = (3, 1, 3)^T$ ,

$$\alpha_0 = \frac{(r^{(0)}, r^{(0)})}{(Ap^{(0)}, p^{(0)})} = \frac{19}{55}$$

$$x^{(1)} = x^{(0)} + \alpha_0 p^{(0)} = \frac{19}{55}(3, 1, 3)^T$$



## 第二步：计算

$$r^{(1)} = r^{(0)} - \alpha_0 A p^{(0)} = -\frac{6}{55}(1, -6, 1)^T$$

$$\beta_0 = \frac{(r^{(1)}, r^{(1)})}{(r^{(0)}, r^{(0)})} = \frac{72}{3025}, \alpha_1 = \frac{(r^{(1)}, r^{(1)})}{(A p^{(1)}, p^{(1)})} = \frac{55}{57}$$

$$p^{(1)} = r^{(1)} + \beta_0 p^{(0)} = -\frac{114}{3025}(-1, 18, -1)^T$$

$$x^{(2)} = x^{(1)} + \alpha_1 p^{(1)} = (1, 1, 1)^T$$

$$r^{(2)} = b - A x^{(2)} = (0, 0, 0)^T$$

## §7.4.3 实用的共轭梯度法及其收敛性

理论上，共轭梯度法为直接法，最多  $n$  步可得精确解；

实际上，因舍入误差的出现，使得  $r^{(k)}$  的正交性损失，不能有限步终止迭代计算；

实际计算，将 CG 方法看作迭代方法使用，通过  $\|r^{(k)}\|$  的大小或最大迭代步数决定是否终止计算。

### 实用迭代算法：

$x$ =初值；

$k = 0, r = b - Ax, \rho = r^T r;$

while  $(\sqrt{\rho} > \varepsilon \|b\|_2) \& (k \leq k_{\max})$

$k = k + 1;$

    if  $k = 1$

$p = r;$

    else

$\beta = \rho / \tilde{\rho}, p = r + \beta p;$

    end

$w = Ap; \alpha = \rho / p^T w; x = x + \alpha p;$

$r = r - \alpha w; \tilde{\rho} = \rho; \rho = r^T r;$

end

## 共轭梯度法的优点

- 算法中，矩阵  $A$  仅用于求向量  $w = Ap$ , 可充分运用矩阵稀疏性质；
- 不需要预先估计参数，可以直接计算；
- 每次迭代所需的计算，主要是向量之间的运算，便于并行化.

## 定理

如果矩阵  $A = I + B$  且  $\text{rank}(B) = r$ ，则共轭梯度法最多迭代  $r + 1$  步可得方程组的精确解.

证明：注意到  $\text{rank}(B) = r$  意味着

$$\text{span}\{r^{(0)}, Ar^{(0)}, \dots, A^k r^{(0)}\} = \text{span}\{r^{(0)}, Br^{(0)}, \dots, B^k r^{(0)}\}$$

的维数不会超过  $r + 1$ ，固有前面的定理可知，结论成立.

上面定理说明，当线性方程组系数矩阵与单位矩阵相差一个秩为  $r$  的矩阵且  $r$  很小时，CG 算法收敛很快.

## 定理

用共轭梯度法得到方程组的近似解  $x^{(k)}$  满足

$$\|x^{(k)} - x^*\|_A \leq 2 \left( \frac{\sqrt{\kappa_2} - 1}{\sqrt{\kappa_2} + 1} \right)^k \|x^{(0)} - x^*\|_A, (\kappa_2 = \kappa_2(A)).$$

- 其证明可参考北京大学出版社《数值线性代数》.
- 定理显示 CG 法比最速下降法收敛得快.

# 目 录

- ① Jacobi 迭代法与 Gauss-Seidel 迭代法
- ② Jacobi 迭代与 Gauss-Seidel 迭代的收敛性分析
- ③ 超松弛迭代法
- ④ 共轭梯度法
- ⑤ 非线性方程组的迭代解法

## §7.5 非线性方程组的迭代解法

考虑  $n$  个方程的  $n$  元非线性方程组的一般形式

$$\begin{cases} f_1(x_1, \cdots, x_n) = 0 \\ f_2(x_1, \cdots, x_n) = 0 \\ \vdots \\ f_n(x_1, \cdots, x_n) = 0 \end{cases}$$

$f_i$  为定义在区域  $D$  的  $n$  元实值函数，且至少一个为非线性函数。如

$$\begin{cases} xy = z^3 + 1 \\ xyz + y^2 = x^2 + 2 \\ e^x + z = e^y + 3 \end{cases}$$

本节主要介绍牛顿迭代法。

## §7.5.1 牛顿迭代法

Newton 迭代法的迭代格式: 利用多元函数 Taylor 展开公式可得

$$f(x^*) = f(x^{(k)}) + \nabla f(x^{(k)})(x^* - x^{(k)}) + R(x^*, x^{(k)}),$$

其中  $R(x, x^{(k)}) = O((x - x^{(k)})^2)$ ,

$$\nabla f(x^{(k)}) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}$$

为函数  $f$  的 Jacobi 矩阵. 忽略高阶无穷小项, 可得近似

$$\nabla f(x^{(k)})(x^* - x^{(k)}) = -f(x^{(k)})$$

若  $\nabla f(x^{(k)})$  可逆, 则可构造迭代格式

$$x^{(k+1)} = x^{(k)} - \nabla f(x^{(k)})^{-1}f(x^{(k)}), \quad k = 0, 1, 2 \dots$$

称上述公式为 **Newton 迭代格式**。

## 存在的问题

在实际迭代时, Newton 迭代方法计算量庞大, 既要计算 Jacobi 矩阵, 还要求逆.

实际计算时, 分两步完成:

$$\nabla f(x^{(k)})y^{(k)} = -f(x^{(k)}), \quad x^{(k+1)} = x^{(k)} + y^{(k)}.$$



## §7.5.2 Broyden 秩 1 方法

Broyden 秩 1 方法是 Newton 迭代方法一种改进. 其优点如下

- 仅需第一步计算 Jacobi 矩阵并求逆, 以后每步只需作矩阵和向量相乘;
- 其运算量  $O(n^2)$ , 大大降低工作量.

Broyden 秩 1 方法的原理如下:

由多元 Taylor 展开公式可知

$$f(x^{(k-1)}) = f(x^{(k)}) + \nabla f(x^{(k)})(x^{(k-1)} - x^{(k)}) + R(x^{(k-1)}, x^{(k)}),$$

其近似公式为

$$\nabla f(x^{(k)})(x^{(k)} - x^{(k-1)}) = f(x^{(k)}) - f(x^{(k-1)}),$$

记

$$A^{(k)} = \nabla f(x^{(k)}), y^{(k-1)} = (x^{(k)} - x^{(k-1)}), g^{(k-1)} = f(x^{(k)}) - f(x^{(k-1)})$$

从而有牛顿方程

$$A^{(k)} y^{(k-1)} = g^{(k-1)}.$$

令

$$\begin{aligned} A^{(k)} &= A^{(k-1)} + \Delta A^{(k)} \longrightarrow \text{秩1矩阵} \\ &= A^{(k-1)} + u^{(k-1)} y^{(k-1)T} \longrightarrow u^{(k-1)} \text{为待定向量} \end{aligned}$$

将其代入牛顿迭代方程得

$$g^{(k-1)} = A^{(k)} y^{(k-1)} = A^{(k-1)} y^{(k-1)} + u^{(k-1)} y^{(k-1)T} y^{(k-1)}$$

从而可得

$$u^{(k-1)} = \frac{g^{(k-1)} - A^{(k-1)} y^{(k-1)}}{y^{(k-1)T} y^{(k-1)}}$$

$$A^{(k)} = A^{(k-1)} + \frac{g^{(k-1)} - A^{(k-1)} y^{(k-1)}}{y^{(k-1)T} y^{(k-1)}} (y^{(k-1)})^T$$

## 引理

如果  $A$  非奇异,  $x, y \in R^n$ , 若  $y^T A x \neq -1$ , 则  $A + xy^T$  可逆, 且

$$(A + xy^T)^{-1} = A^{-1} - \frac{A^{-1}xy^TA^{-1}}{1 + y^TA^{-1}x}.$$

由上面的引理可得  $A^{(k)}$  的逆与  $A^{(k-1)}$  的逆之间的关系

$$(A^{(k)})^{-1} = (A^{(k-1)})^{-1} + \frac{[(A^{(k-1)})^{-1}g^{(k-1)} - y^{(k-1)}](y^{(k-1)})^T(A^{(k-1)})^{-1}}{(y^{(k-1)})^T(A^{(k-1)})^{-1}g^{(k-1)}} \quad (5.15)$$

## Broyden 秩 1 算法

选初值  $x^{(0)}$ , 计算  $(A^{(0)})^{-1} = (\nabla f(x^{(0)}))^{-1}$ ,  $x^{(1)} = x^{(0)} - (A^{(0)})^{-1}f(x^{(0)})$ ,  
for  $k=1,2,\dots$ ,

$y = x^{(k)} - x^{(k-1)}, g = f(x^{(k)}) - f(x^{(k-1)})$ ;

运用公式 (5.15) 计算  $(A^{(k)})^{-1}$ ;

$x^{(k+1)} = x^{(k)} - (A^{(k)})^{-1}f(x^{(k)})$ ;

若迭代条件满足, 终止循环并输出  $x^{(k+1)}$ .

end

# 知识小结

## 主要内容

Jacobi 迭代法、Gauss-Seidel 迭代法、SOR 迭代法、CG 算法

收敛性分析

非线性方程组求解的迭代算法：Newton 迭代法、Broyden 算法

## 重点及难点

重点：Jacobi 迭代法、Gauss-Seidel 迭代法、SOR 迭代法、CG 算法

难点：CG 算法、收敛性

Many thanks for your attention !



中國石油大學 (华东)  
CHINA UNIVERSITY OF PETROLEUM